

Paper title - English

Título do artigo - somente para documento escrito em Português

BRAGA, S. J.*; GOMI, E. S.*

*Escola Politécnica da Universidade de São Paulo

Abstract—Abstract here.**Keywords**— word 1; word 2.**Resumo**— É necessária a inserção do resumo para artigo escrito em Português.**Palavras-chave**— palavra 1; palavra 2.**Classificação**— Mestrado**Categoria**— Iniciante

I. INTRODUÇÃO

II. DIAGNÓSTICO DE GLAUCOMA

Glaucoma é uma neuropatia óptica crônica multifatorial e de lenta progressão que causa perda de campo visual periférico e é a segunda maior causa de cegueira no mundo, estima-se que atingirá 79,6 milhões de pessoas até 2020 [1]. Essa doença caracteriza-se pela perda da camada de fibras nervosas no olho, o que pode causar cegueira se não for tratado corretamente [2]. O dano na camada de fibras nervosas se dá antes de alteração no campo visual do paciente, por isso o diagnóstico precoce é um fator importante para evitar a perda da visão [3].

O glaucoma é diagnosticado por um oftalmologista especialista, utilizando exames funcionais e estruturais. Os exames funcionais avaliam o campo visual do paciente em busca de reduções na visão. Os exames estruturais avaliam a camada de fibras nervosas para identificar alterações na espessura. Por ser uma doença que não apresenta sintomas em estágios iniciais, um oftalmologista que não é especialista pode não identificar a doença no paciente antes de haver danos ao campo visual [4].

Um dos exames estruturais utilizados no diagnóstico de glaucoma é a tomografia de coerência óptica (OCT). Análogo a um ultrassom, o OCT utiliza feixes de luz para medir a espessura das estruturas intraoculares. Utilizando um feixe de laser, o OCT mede as espessuras das diferentes estruturas através do tempo que cada uma leva para refletir de volta a luz [5].

No diagnóstico de glaucoma, o OCT é empregado para identificar alterações na camada de fibras nervosas. No exame é analisada uma faixa circular ao longo do nervo óptico e feita a projeção da espessura em cada ponto. Na figura 1 temos um exemplo de saída de um equipamento de OCT, onde são exibidos os gráficos de espessura em microns. Um especialista em glaucoma pode identificar alterações nas espessuras do nervo óptico em um paciente com glaucoma inicial antes que haja danos ao campo visual.

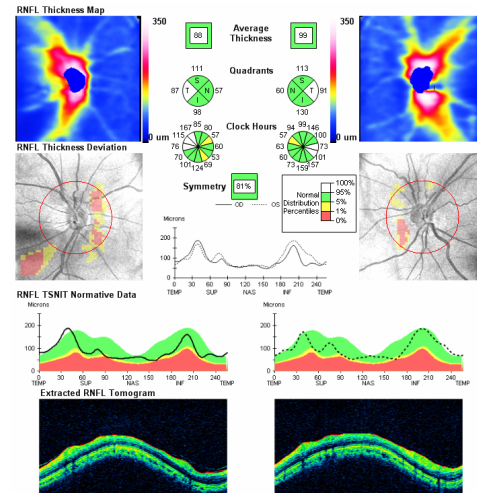


Figura 1. Saída de um exame de OCT [4].

III. REDES NEURAIS PROFUNDAS

A. Transfer Learning

B. Redes pré-treinadas

IV. EXPERIMENTOS E RESULTADOS

Os experimentos foram conduzidos em um servidor com Ubuntu 16.04 com duas GPUs NVidia Quadro K5200 com 8GB de memória cada, 24 CPUs Intel Xeon e 128GB de memória RAM. O framework de deep learning utilizado em todos os experimentos foi o Caffe, fornecido pela universidade de Berkeley [6].

O objetivo dos experimentos, com e sem transfer learning, é a classificação binária de olhos normais ou com glaucoma em imagens de OCT. A performance das redes foram avaliadas utilizando um conjunto menor de imagens não vistas para classificação e cálculo das métricas de avaliação. O mesmo conjunto de imagens é utilizado em todos os experimentos. O dataset, pré-processamento e resultados são descritos em detalhes nas próximas seções.

A. Dataset

O dataset original foi obtido com o departamento de oftalmologia da Unicamp. O dataset consiste de imagens de OCT com tamanho 136x136 de 56 olhos com glaucoma e 66 olhos normais, totalizando 122 pacientes. Os gráficos de

espessura de fibras nervosas foram obtidos através da extração das imagens do PDF do exame. Foram selecionados para o experimento somente os olhos de pacientes que foram manualmente classificados por especialistas.

Para a separação do dataset em treino e validação, foram selecionados 20% de olhos normais e 20% de olhos com glaucoma para validação, e o restante para treino, totalizando 98 imagens de treino e 24 para validação. As imagens selecionadas para teste não estão presentes no dataset de treino, para que o algoritmo possa classificar imagens ainda não vistas.

Para evitar overfitting, foi empregada uma técnica para aumentar o número de exemplos a partir das imagens no dataset de treino. Cada imagem foi rotacionada 100 vezes em ângulos aleatórios entre 0 e 360 graus, gerando assim um dataset de treino com 9800 imagens. As imagens de validação não foram rotacionadas.

B. Pré-processamento

Para utilização do transfer learning, foi necessário fazer a subtração do pixel médio em todas as imagens do dataset de treino. O valor médio de cada pixel da imagem é calculado sobre todas as imagens do dataset de treino. Essa imagem média é então subtraída de cada imagem do dataset. Dessa forma, todos os pixels de entrada estão na mesma ordem de grandeza, evitando que os gradientes desapareçam ou explodam.

Onde houveram falhas na aquisição da imagem, gerando áreas escuras, pixels com valores RGB próximos ao preto foram substituídos pelo valor de preto absoluto RGB (0, 0, 0) para que não tenham influência sobre a decisão do classificador.

C. Resultados com transfer learning

Neste experimento, utilizamos a mesma arquitetura da rede VGG16, alterando a saída da última camada totalmente conectada para duas saídas, correspondente às duas classes a serem classificadas: normal e glaucoma. A camada de entrada da rede também foi alterada para a resolução das imagens do nosso dataset. As imagens do dataset Imagenet com que a rede foi treinada tinham a resolução de 224x224 pixels, enquanto que as imagens de OCT têm resolução de 136x136 pixels.

Os pesos pré-treinados foram carregados para inicialização apenas das camadas convolucionais. As três últimas camadas totalmente conectadas foram iniciadas com valores aleatórios devido à diferença de resolução entre as imagens do dataset Imagenet e as imagens de OCT classificadas nesse experimento. Essa diferença gera quantidades de parâmetros diferentes na saída da última camada convolucional. Sendo assim, as camadas totalmente conectadas foram inicializadas com valores aleatórios de uma distribuição normal com desvio padrão 0.01.

O treinamento foi realizado em todas as camadas da rede, utilizando o gradiente descendente estocástico por 5000 iterações, com mini batches de 15 imagens. Os parâmetros de momentum e weight decay foram definidos como 0.9 e 0.0005, respectivamente. A taxa de aprendizagem inicial foi

de 0.001. A cada 1000 iterações a taxa de aprendizagem foi diminuída utilizando a equação 1.

$$base_lr * \gamma^{\lfloor \frac{iter}{step} \rfloor} \quad (1)$$

Onde $base_lr$ é a taxa de aprendizagem inicial, γ é um parâmetro do Caffe definido com o valor 0.1, $iter$ é o número da iteração atual e $step$ é um parâmetro definido como 1000.

A validação do modelo foi feita utilizando um dataset de 24 imagens não vistas pelo algoritmo durante a fase de treinamento. Foi obtida acurácia final de 95.8%, com sensibilidade de 100% e especificidade de 92.3%. A figura 2 mostra exemplos de imagens classificadas pela rede durante a fase de validação. O gráfico na figura 3 mostra a evolução dos valores de perda e acurácia durante o processo de treinamento da rede. A validação foi feita a cada 1000 iterações. É possível identificar a estabilização da acurácia após 1000 iterações, quando o valor de perda do treinamento chega próximo à zero.

D. Resultados sem transfer learning

No experimento sem transfer learning, foi utilizada a mesma arquitetura de rede VGG16, porém sem utilizar os pesos pré-treinados. As camadas convolucionais foram inicializadas utilizando o algoritmo xavier [7], as últimas camadas totalmente conectadas foram inicializadas utilizando valores de distribuição normal com desvio padrão 0.01.

O treino foi realizado com 10000 iterações, utilizando mini batches de 20 imagens e gradiente descendente estocástico. A taxa de aprendizagem foi inicializada em 0.1 e diminuída a cada 5000 iterações, utilizando a equação 1. Os parâmetros de momentum e weight decay não foram alterados, utilizando os mesmos definidos no experimento com transfer learning. Para evitar que os gradientes aumentassem muito, foi utilizada a técnica de gradient clipping para que os gradientes não sejam maior que 1.

V. DISCUSSÃO

VI. CONCLUSÃO

REFERÊNCIAS

- [1] QUIGLEY, H. A. The number of people with glaucoma worldwide in 2010 and 2020. *British Journal of Ophthalmology*, BMJ, v. 90, n. 3, p. 262–267, mar 2006. Disponível em: <<http://dx.doi.org/10.1136/bjo.2005.081224>>.
- [2] QUIGLEY, H. A. Glaucoma. *The Lancet*, v. 377, n. 9774, p. 1367–1377, 2011.
- [3] MALIK, R.; SWANSON, W. H.; GARWAY-HEATH, D. F. 'structure-function relationship' in glaucoma: past thinking and current concepts. *Clinical & Experimental Ophthalmology*, Wiley-Blackwell, v. 40, n. 4, p. 369–380, apr 2012. Disponível em: <<http://dx.doi.org/10.1111/j.1442-9071.2012.02770.x>>.
- [4] DIAS, M. *Geracao de Populacoes Artificiais para Treinamento de Classificadores de Apoio ao diagnostico de Glaucoma*. Tese (Doutorado) — Escola Politecnica da USP, 2009.
- [5] HUANG, D. et al. Optical coherence tomography. *Science*, American Association for the Advancement of Science, v. 254, n. 5035, p. 1178–1181, 1991. ISSN 0036-8075. Disponível em: <<http://science.sciencemag.org/content/254/5035/1178>>.
- [6] JIA, Y. et al. Caffe: Convolutional architecture for fast feature embedding. *arXiv preprint arXiv:1408.5093*, 2014.

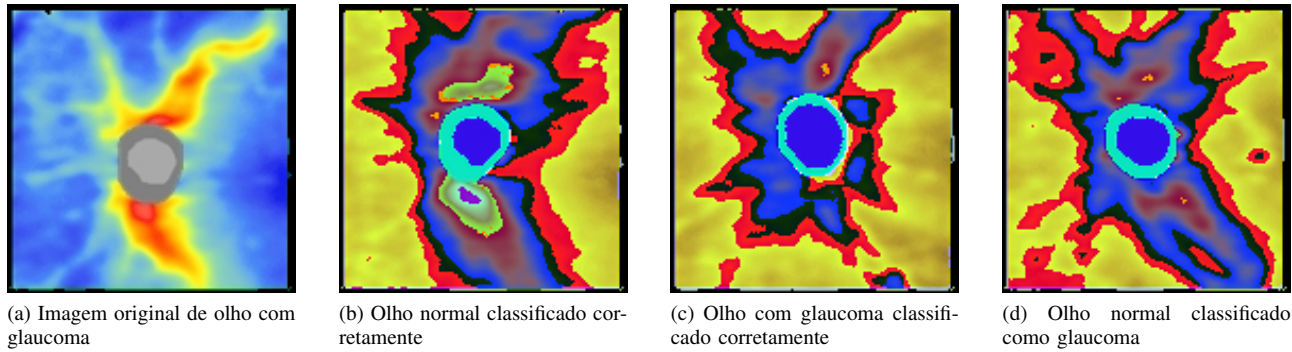


Figura 2. Exemplos de imagens classificadas pela rede com transfer learning. Imagem 2a mostra um exemplo antes da subtração da imagem média. Figuras 2b à 2d mostram exemplos classificados durante a validação da rede.




Figura 3. Acurácia e perda de treino e validação da rede VGG16 com transfer learning.

- [7] GLOROT, X.; BENGIO, Y. Understanding the difficulty of training deep feedforward neural networks. In: TEH, Y. W.; TITTERINGTON, M. (Ed.). *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*. Chia Laguna Resort, Sardinia, Italy: PMLR, 2010. (Proceedings of Machine Learning Research, v. 9), p. 249–256. Disponível em: <<http://proceedings.mlr.press/v9/glorot10a.html>>.